Comunicação entre Processos



Comunicação entre Processos

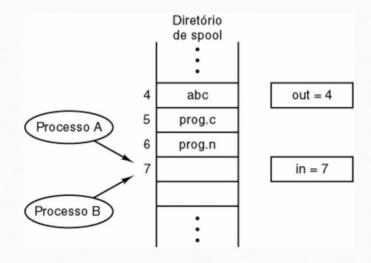
- Frequentemente, processos precisam se comunicar com outros processos.
 - Ex.: a saída do primeiro processo tem de ser passada para um segundo e, assim por diante.
 - o De preferência de uma maneira bem estruturada sem usar interrupções.
- Há 3 tópicos que devem ser abordados:
 - Como um processo passa informações para outro;
 - Como garantir que dois ou mais processos não invadam uns aos outros quando envolvidos em atividades críticas;
 - Sequência adequada quando existirem dependências.
 - Ex.: se o processo *A* produz dados e o processo *B* os imprime, *B* tem de esperar até que *A* tenha produzido alguns dados antes de começar a imprimir.

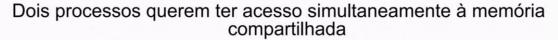
Os mesmos problemas e soluções se aplicam aos threads.



Condições de Disputa (Corrida)

• Situações nas quais dois ou mais processos estão lendo ou escrevendo algum dado compartilhado e cujo resultado final depende das informações de quem e quando executa precisamente.







Regiões Críticas

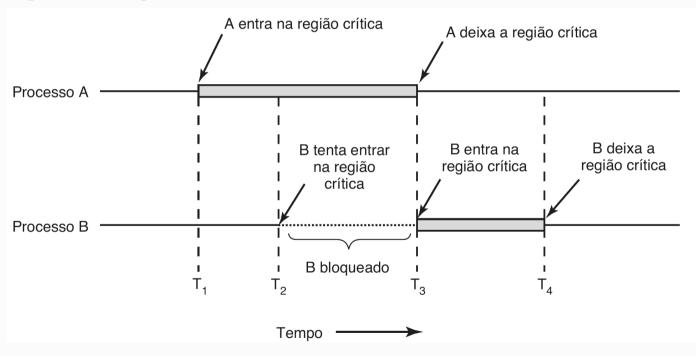
- Como evitar as condições de corrida?
 - A chave para evitar problemas em situações envolvendo memória compartilhada, arquivos compartilhados e tudo o mais compartilhado é encontrar alguma maneira de proibir mais de um processo de ler e escrever os dados compartilhados ao mesmo tempo.
 - Exclusão mútua (exclusividade de acesso): maneira de se certificar de que se um processo está usando um arquivo ou variável compartilhados, os outros serão impedidos de realizar a mesma coisa.
- Durante parte do tempo, um processo está ocupado realizando computações internas e outras coisas que não levam a condições de corrida.
- No entanto, às vezes um processo tem de acessar uma memória compartilhada ou arquivos, ou realizar outras tarefas críticas que podem levar a corridas.
 - Essa parte do programa é chamada de região crítica ou seção crítica.
 - o Garantir que dois processos NÃO estejam em suas regiões críticas ao mesmo tempo.
 - Serialização.

Regiões Críticas

- Embora essa exigência evite as condições de corrida, ela não é suficiente para garantir que processos em paralelo cooperem de modo correto e eficiente usando dados compartilhados.
- Necessário que quatro condições se mantenham para chegar a uma boa solução:
 - Dois processos jamais podem estar simultaneamente dentro de suas regiões críticas.
 - Nenhuma suposição pode ser feita a respeito de velocidades ou do número de CPUs.
 - Nenhum processo executando fora de sua região crítica pode bloquear qualquer processo.
 - Nenhum processo deve ser obrigado a esperar eternamente para entrar em sua região crítica.

Exclusão mútua usando regiões críticas

Comportamento esperado:





Região Crítica

- Cabe ao **programador**:
 - o Detectar as regiões críticas no seu código e
 - o Implementar as rotinas de proteção e exclusão mútua.
- Reconhecer a parte do código que pode trazer problemas:
 - Não é uma tarefa fácil!
 - Exige muitos testes e tempo.



Exclusão Mútua com Espera Ociosa

- Desabilitando Interrupções.
- Variáveis de Impedimento.
- Alternância Obrigatória.
- Solução de Peterson.
- A Instrução TSL.



Desabilitando Interrupções

- É a solução mais simples: cada processo desabilita todas as interrupções logo depois de entrar na região crítica e reabilita imediatamente antes de sair dela;
 - Com as interrupções desligadas, a CPU não será chaveada para outro processo.
- Não é interessante porque não é prudente dar aos processos dos usuários o poder de desligar interrupções;
 - E se um deles desligasse uma interrupção e nunca mais a ligasse de volta? Isso poderia ser o fim do sistema.
 - Se o sistema é um multiprocessador, desabilitar interrupções afeta somente a CPU que executou a instrução disable. As outras continuarão executando e podem acessar a memória compartilhada.
- É uma técnica bastante útil dentro do próprio SO, mas inadequada como um mecanismo geral de exclusão mútua para processos de usuário.



Variáveis de Impedimento

- É uma solução de software;
- Há uma única variável compartilhada entre os dois processos (lock trava), contendo o valor 0;
- Quando um processo quer entrar na sua região crítica, ele testa a trava:
 - Se *lock* for 0, o processo altera essa variável para 1 e entra na região;
 - Se *lock* estiver com valor 1, o processo simplesmente aguardará até que ela se torne 0;
- Só que essa técnica possui uma falha como diretório de spool.
 - Suponha que um processo lê a trava e vê que ela é 0. Antes que ele possa configurar a trava para 1, outro processo está escalonado, executa e configura a trava para 1.
 Quando o primeiro processo executa de novo, ele também configurará a trava para 1, e dois processos estarão nas suas regiões críticas ao mesmo tempo.



Alternância Obrigatória

- Contém uma variável inteira (*turn*), inicialmente com 0, que serve para controlar a vez de quem entra na região crítica e examinar ou atualizar a memória compartilhada.
 - o Inicialmente, o processo 0 inspeciona *turn*, descobre que ele é 0 e entra na sua região crítica. O processo 1 também encontra lá o valor 0 e, portanto, espera em um laço fechado testando continuamente *turn* para ver quando ele vira 1.
 - Quando o processo 0 deixa a região crítica, ele configura *turn* para 1, a fim de permitir que o processo 1 entre em sua região crítica.
- Testar continuamente uma variável até que algum valor apareça é chamado de **espera ocupada**. Em geral ela **deve ser evitada**, já que desperdiça tempo da CPU. Apenas quando há uma expectativa razoável de que a espera será curta, a espera ocupada é usada.

Uma trava que usa a espera ocupada é chamada de **trava giratória** (*spin lock*).



Alternância Obrigatória

Solução proposta para o problema da região crítica (a) Processo 0. (b) Processo 1.

- Alternar a vez não é uma boa ideia quando um dos processos for muito mais lento que o outro.
 - O processo pode será bloqueado por um outro processo que não está na sua região crítica.
 - O Na realidade, essa solução exige que os dois processos alternem-se estritamente na entrada em suas regiões críticas.



Solução de Peterson

- Antes de usar as **variáveis compartilhadas** (entrar na região crítica), cada processo chama *enter_region* com seu **próprio número de processo**, 0 ou 1, como parâmetro. Essa chamada fará que ele espere, se necessário, até que seja seguro entrar.
- Após haver terminado com as variáveis compartilhadas, o processo chama *leave_region* para indicar que ele terminou e para permitir que outros processos entrem, se assim desejarem.

```
#define FALSE 0
#define TRUE
                                    /* número de processos */
#define N
int tum;
                                    /* de quem é a vez? */
                                    /* todos os valores inicialmente em 0 (FALSE) */
int interested[N];
                                    /* processo é 0 ou 1 */
void enter_region(int process);
                                   /* número de outro processo */
    int other:
    other = 1 - process;
                                    /* o oposto do processo */
    interested[process] = TRUE:
                                    /* mostra que você está interessado */
                                    /* altera o valor de turn */
     tum = process:
     while (turn == process && interested[other] == TRUE) //* comando nulo */;
void leave_region(int process)
                                    /* processo: quem está saindo */
    interested[process] = FALSE; /* indica a saída da região crítica */
```



Solução de Peterson

• Resumindo...

- Inicialmente, nenhum processo está na sua região crítica.
- Agora o processo 0 chama *enter_region* e indica o seu interesse alterando o valor de seu elemento de arranjo e alterando *turn* para 0.
- Como o processo 1 não está interessado, *enter_region* retorna imediatamente.
- Se o processo 1 fizer agora uma chamada para *enter_region*, ele esperará ali até que *interested*[0] mude para *FALSE*, um evento que acontece apenas quando o processo 0 chamar *leave_region* para deixar a região crítica.



Instrução TSL

- Requer um pequeno auxílio do *hardware*.
- Computadores projetados com múltiplos processadores tem a instrução TSL RX, LOCK.
- TSL (*Test and Set Lock*) teste e atualize a variável de impedimento: ele lê o conteúdo da palavra *lock* da memória para o registrador e então armazena um valor diferente de zero no endereço de memória *lock*.
- As operações de leitura e armazenamento de uma palavra são seguramente indivisíveis: nenhum outro processador pode acessar a palavra na memória até que a instrução tenha terminado.
- A CPU executando a instrução TSL impede o acesso ao barramento de memória para proibir que outras CPUs acessem a memória até ela terminar.



Instrução TSL

Entrando e saindo de uma região crítica:

Para usar a instrução TSL, usa-se uma variável compartilhada, lock, para coordenar o acesso à memória compartilhada. Quando lock está em 0, qualquer processo pode configurá-lo para 1 usando a instrução TSL e, então, ler ou escrever a memória compartilhada. Quando terminado, o processo configura *lock* de volta para 0 usando uma instrução mover comum.

enter region:

TSL REGISTER.LOCK

I lock valia zero?

CMP REGISTER.#0 JNE enter region

I se fosse diferente de zero, lock estaria ligado,

l copia lock para o registrador e põe lock em 1

portanto continue no laco de repetição

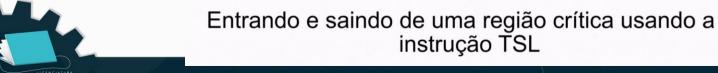
RET I retorna a guem chamou; entrou na região crítica

leave region:

MOVE LOCK, #0

I coloque 0 em lock

RET I retorna a quem chamou





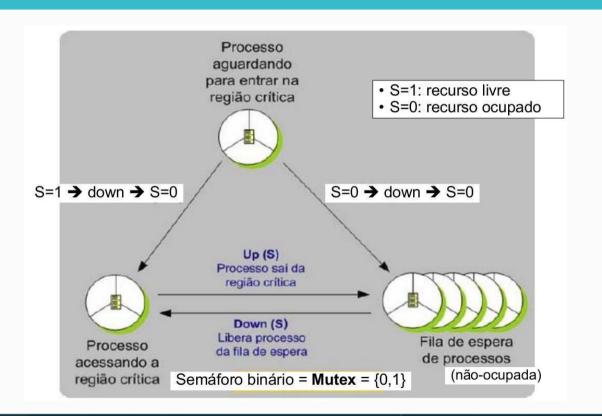
Semáforos (S)

- Conceito proposto por E. W. Dijkstra, em 1965.
- Permite implementar, de forma simples:
 - Exclusão mútua
 - Sincronização entre processos
- Um dos principais mecanismos utilizados:
 - Nos projetos de SO e nas aplicações concorrentes.
 - Nas linguagens de programação (rotinas para semáforos).
- Um semáforo (S) é:

COMPUTAÇÃO

- Uma variável especial protegida pelo SO (não negativa).
- Manipulada por duas instruções atômicas:
 - *Down* (decremento) generalização de *sleep*
 - *Up* (incremento) generalização de *wakeup*
- Se S=zero e *Down: thread* fica em espera (não ocupada).

Semáforos





Semáforos

- A operação *down* em um semáforo **confere para ver se o valor é maior do que 0.**
 - Se for, ele decrementará o valor (isto é, gasta um sinal de acordar armazenado) e apenas continua.
 - Se o valor for 0, o processo é colocado para dormir sem completar o *down* para o momento.
- Conferir o valor, modificá-lo e possivelmente dormir são feitos como uma única **ação atômica** indivisível.
 - Uma vez que a operação de semáforo tenha começado, nenhum outro processo pode acessar o semáforo até que a operação tenha sido concluída ou bloqueada.
 - o Essencial para solucionar problemas de sincronização e evitar condições de corrida.
- A operação *up* incrementa o valor de um determinado semáforo.
 - Se um ou mais processos estiverem dormindo naquele semáforo, incapaz de completar uma operação *down* anterior, um deles é escolhido pelo sistema e é autorizado a completar seu *down*.
 - Após um up com processos dormindo em um semáforo, ele ainda estará em 0, mas haverá menos processos dormindo nele.



Mutexes

- Versão simplificada dos semáforos: quando a capacidade do semáforo de fazer contagem não é necessária.
- Bons somente para gerenciar a exclusão mútua de algum recurso ou trecho de código compartilhados.
- **Fáceis e eficientes de implementar** → úteis em pacotes de *threads* que são implementados inteiramente no espaço do usuário.
- Um mutex é uma variável compartilhada que pode estar em um de dois estados: destravado ou travado.
 - Apenas 1 bit é necessário para representá-lo, mas na prática muitas vezes um inteiro é usado, com 0 significando destravado e todos os outros valores significando travado.
 - **Duas rotinas** são usadas com mutexes:
 - Quando um *thread* (ou processo) precisa de acesso a uma região crítica, ele chama *mutex_lock*. Se o mutex estiver destravado naquele momento (significando que a região crítica está disponível), a chamada seguirá e o *thread* que chamou estará livre para entrar na região crítica.
 - Se o mutex já estiver travado, o *thread* que chamou será bloqueado até que o *thread* na região crítica tenha concluído e chame *mutex_unlock*.
 - Se múltiplos *threads* estiverem bloqueados no mutex, um deles será escolhido ao acaso e liberado para adquirir a trava.

Deadlock (impasse)

- Ocorre quando um processo aguarda por:
 - Um recurso que nunca estará disponível ou
 - Um evento que nunca ocorrerá.
- Causa provável:
 - Compartilhamento de recursos (periféricos, arquivos etc).
 - o Onde a exclusão mútua é necessária.
- Coffman, Elpick e Shoshani, demonstraram, em 1971:
- Para ocorrer deadlock:
 - 4 condições são essenciais (simultâneas).



Condições necessárias para o Deadlock (simultâneas)

Exclusão mútua:

- Recurso está alocado a um único processo ou
- Está disponível.

• Posse e espera por recurso:

- o Processo retém um recurso (posse) e
- Pode requisitar outro recurso (espera).

Não-preempção:

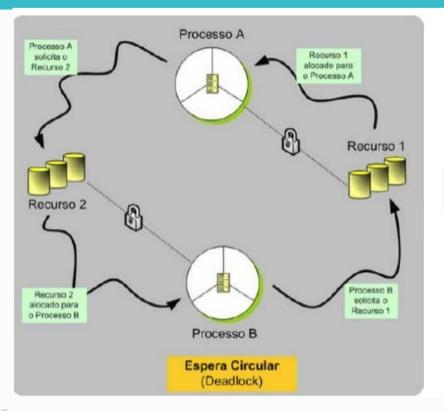
- Processo obtém um recurso (e só ele pode liberá-lo).
- SO não tem poder de liberá-lo (quando necessário).
 - Não-preemptíveis: impressora, gravador de CD.
 - Preemptíveis: memória RAM, disco rígido.

• Espera circular (gera um grafo cíclico de 2 ou mais processos)

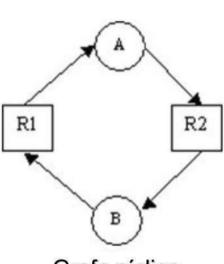
- Processo A espera recurso 2 ora alocado ao Processo B e
- o Processo B espera recurso 1 ora alocado ao Processo A.



Deadlock (impasse)



COMPUTAÇÃO



Grafo cíclico

Soluções para o *Deadlock*

- Prevenção:
 - Negar qualquer uma das 4 condições necessárias.
- Anulação Dinâmica:
 - Alocar recursos criteriosamente.
- **Detecção e recuperação:** muito caro
 - Deixar ocorrer, detecta e elimina:
 - Reverter o estado do processo (*rollback*).
 - Tomar o recurso de um dos processos (preempção).
 - Encerrar um dos processos envolvidos.
- Ignorar (Algoritmo do Avestruz)
 - Muitos SO modernos ignoram o deadlock (evento raro):
 - Windows.
 - Unix like(Linux).
 - Assim: assume-se a possibilidade de **reiniciar** o sistema.



Adiamento Indefinido (*Starvation = inanição*)

- É uma situação, também conhecida como:
 - Postergação indefinida
 - Espera indefinida
 - Inanição ou
 - Starvation
- Processo **nunca** consegue:
 - Executar sua região crítica, ou seja
 - Acessar o recurso compartilhado.



Adiamento Indefinido (Starvation = inanição)

- Por que isso ocorre?
 - Quando o recurso desejado é liberado.
 - SO sempre escalona outro processo para o recurso.
- Solução: técnica de envelhecimento *aging*:
 - Elevando a **prioridade do processo** gradativamente.
 - Enquanto ele espera por um recurso.



Ler!!!

Capítulo 2 do Livro Texto.



Atividade

Atividade no AVA.

